# Algoritmo e Estrutura de Dados II
# CTCO02

## Organização de Arquivos

Vanessa Souza

Universidade Federal de Itajubá – Instituto de Matemática e Computação

# Arquivos

Conceitos Básicos

# Disco Rígido – Trilhas

- Trilha - porção circular da superfície do disco, sobre a qual passa a cabeça de leitura/gravação.
  - Disco flexível - 80 trilhas em cada superfície
  - Disco rígido - 1.000 ou mais trilhas em cada superfície de cada lâmina

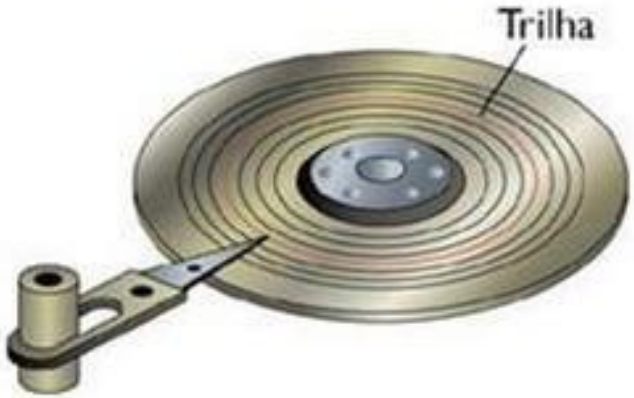

# Disco Rígido – Setores

- Cada trilha é dividida em setores que contêm um número fixo de bytes.
  - Tipicamente, 512 bytes por setor.
- A gravação por zonas atribui mais setores às trilhas que estão nas zonas externas do que àquelas que estão nas zonas internas.

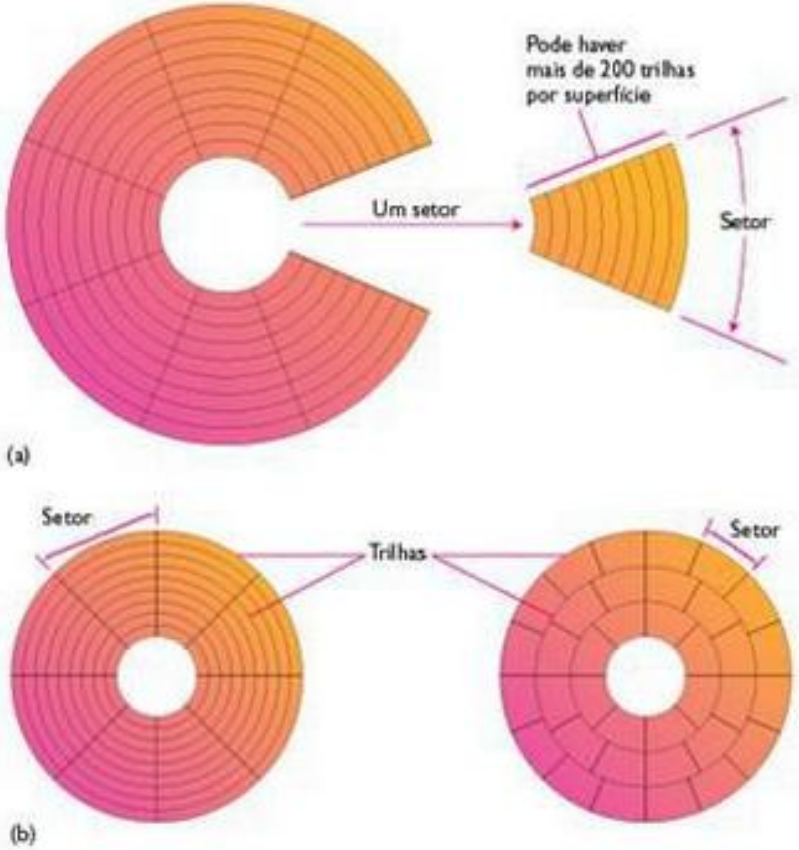

# Arquivo de dados

- Estrutura de dados que armazena o dado propriamente dito.
- Consiste na representação da informação dentro de um computador na forma de bits.
- Um arquivo é identificado por um nome
  - O nome é composto por duas partes separadas por um ponto.
  - A parte após o ponto é chamada extensão que identifica o conteúdo do arquivo.

# Arquivo de dados

- Um *arquivo* é formado por uma coleção de **registros lógicos**, cada um deles representando um objeto ou entidade.

- Um *registro lógico*, ou simplesmente registro, é formado por uma sequência de itens, sendo cada item chamado **campo ou atributo**. Cada item corresponde a uma característica ou propriedade do objeto representado.

- Campo
  - menor unidade lógica de informação em um arquivo
  - uma noção lógica (ferramenta conceitual), não corresponde necessariamente a um conceito físico

# Arquivo de dados

- Cada campo possui um *nome*, um *tipo* e um *comprimento*.

- O comprimento dos valores de um atributo pode ser constante para todos os registros do arquivo, ou variável.

# Arquivo de dados

- Informações em arquivos são, em geral, organizadas logicamente em **campos** e **registros**.

- Registro: conjunto de campos agrupado
  - Nível de organização do arquivo é mais alto
  - Também é uma ferramenta lógica, não física

# Arquivo x Registro

Atributo ou campo

| Nome do Produto | Quantidade | Preço |
|---|---|---|
| Parafusos | 23 | 0,25 |
| Chave de Fenda | 21 | 2,20 |
| Lanterna | 10 | 4,25 |

registro

Estrutura de um arquivo.

- Nome do produto : varchar[30]
- Quantidade : inteiro
- Preço : real

# Registros Lógicos x Registros Físicos

- O registro **lógico** corresponde às instâncias (objetos) do mundo real, cujos atributos são representados pelos campos. Estes registros é que são manipulados pelos programas (sistemas) de aplicação.

- O registro **físico** corresponde à organização física onde as informações são armazenadas (no HD, setores).

- O armazenamento de um arquivo é feito, via de regra, por *blocos* de registros lógicos (um bloco é chamado *registro físico*), sendo, em cada leitura ou gravação, lido ou gravado todo um bloco e não apenas um registro lógico.

# Registros Lógicos x  Registros Físicos

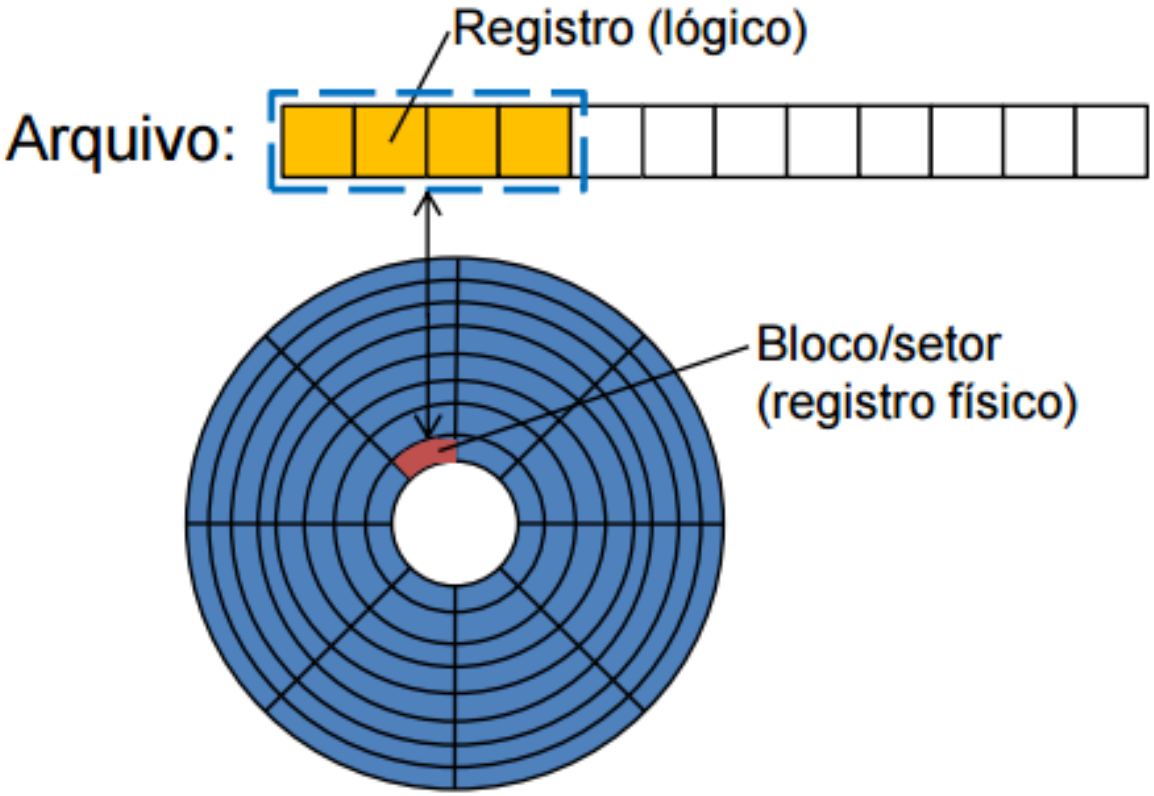

# Registros Lógicos x Registros Físicos

- *Chave de acesso* é a chave utilizada para identificar o(s) registro(s) desejado(s) em uma operação de acesso a um arquivo.

- *Argumento de pesquisa* é o valor da chave de acesso em uma operação.

- *Chave de ordenação* é a chave usada para estabelecer a sequência na qual devem ser dispostos (física ou logicamente) os registros de um arquivo.

# Arquivos

Chave de pesquisa: *1030*

EMPREGADO

| Matricula | Nome | Idade | Salário |
|---|---|---|---|
| 3 | Ademar | 32 | 5000 |
| 5 | Roberto | 25 | 7500 |
| 10 | Gerson | 43 | 6000 |
| 12 | Yeda | 23 | 9000 |
| 30 | Bernardo | 21 | 4500 |
| 50 | Ângela | 29 | 5000 |

Chave de ordenação

# Organização de arquivos

Conceitos Básicos

# Organização de Arquivos

- O tema organização de arquivos refere-se a forma como os registros são armazenados em um arquivo baseado em computador.

- Confunde-se com MÉTODO DE ACESSO, que consiste na forma como esses podem ser recuperados.

- A organização do arquivo determina os métodos de acesso que podem ser utilizados na recuperação dos registros, mas tratam-se de coisas distintas.

# Organização de Arquivos

- Refere-se ao modo como o qual seus dados estão armazenados.

- Quando o arquivo é criado define-se qual forma de organização será adotada.

# Organização de Arquivos

- Organizar um arquivo significa relacionar (mapear) a estrutura lógica e a estrutura física de um arquivo.

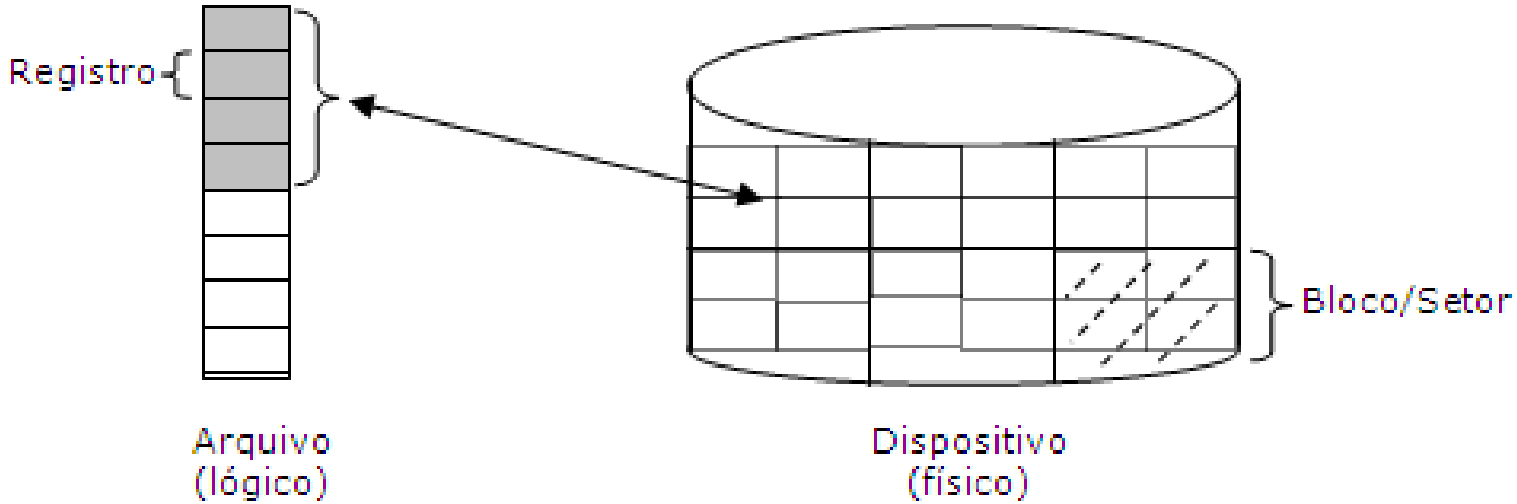


Mapeamento entre estrutura física e lógica.

# Organização de Arquivos

- A organização de arquivo trata do arranjo ou a forma de distribuição dos registros dentro do arquivo, objetivando **agilizar o processo de armazenamento e recuperação de dados**.

- A forma de organização de arquivos (distribuição das entradas) deve levar em consideração as características da aplicação:
  - Volume de dados
  - Frequência de atualizações
  - Frequência de consultas
  - Natureza da chave (primária ou secundária)
  - Meio de armazenamento

# Operações básicas sobre arquivos

- Inserção
  - Adição de um registro no arquivo
- Alteração
  - Corresponde a localização (consulta) de determinado registro, a alteração de um ou mais de seus atributos e atualização
- Exclusão
  - Eliminação de um registro do arquivo

# Operações básicas sobre arquivos

- Consulta
  - Localização de um registro no arquivo.
  - Pode ser de três tipos:
    - *simples* – O usuário especifica o objeto que está procurando (ou sua negação)
    - *por faixa* – O usuário especifica a faixa de valores onde encontram-se os objetos que ele está procurando. Geralmente são utilizados os operados relacionais
    - *booleana* – Corresponde a combinação de uma consulta simples ou por faixa, utilizando um operador lógico

- Reorganização/Ordenação
  - Dependendo da organização de arquivos utilizada é necessário reorganizar ou ordenar os registros, facilitando a sua manipulação.

# Estratégias de organização de arquivos

- Arquivo Sequencial
- Arquivo *Heap*
- Arquivo *Hash*

# Arquivos Sequenciais

# Arquivos Sequenciais

- Em um arquivo sequencial, os registros são armazenados em ordem sequencial
  - Num arquivo sequencial a organização de seus itens faz-se de forma que para acessar um determinado registro é necessário varrer todos os que o antecedem.
  - Se um registro em especial for desejado, todos os registros anteriores devem ser lidos primeiro.

- É a mais conhecida e usada forma de organização de arquivos
  - Serão sempre bastante utilizados pois não há melhor organização do que essa para as situações que exijam varredura ou cobertura periódica de todos os registros de dado arquivo.

# Arquivos Sequenciais x Arquivos Seriais

- Arquivos em série são aqueles nos quais os registros só podem ser acessados em ordem linear, ou seja, o registro de ordem i só pode ser acessado depois do registro de ordem i-1
  - Fitas Magnéticas

- Arquivos sequenciais são aqueles nos quais os registros são armazenados em ordem ascendente ou descendente do valor de um ou mais de seus atributos (chave).
  - Discos Magnéticos

# Arquivos Sequenciais Ordenados (fisicamente)

- Em um arquivo sequencial ordenado fisicamente, os registros são dispostos ordenadamente, obedecendo à sequência determinada por uma chave primária, chamada de chave de ordenação.

EMPREGADO

Chave de pesquisa: *1030*

| Matricula | Nome | Idade | Salário |
|---|---|---|---|
| 3 | Ademar | 32 | 5000 |
| 5 | Roberto | 25 | 7500 |
| 10 | Gerson | 43 | 6000 |
| 12 | Yeda | 23 | 9000 |
| 30 | Bernardo | 21 | 4500 |
| 50 | Ângela | 29 | 5000 |

Chave de ordenação

Estrutura básica:

(Endereço lógico - Chave)

| 3 | Dados | 5 | dados | 10 | dados | 12 | dados | ... |
|---|---|---|---|---|---|---|---|---|
| 1 | | 2 | | 3 | | 4 | | 5 |

(Endereço Físico)

# Arquivos Sequenciais Ordenados (fisicamente)

- Em um arquivo sequencial, os registros são dispostos ordenadamente, obedecendo à sequência determinada por uma chave primária, chamada de chave de ordenação.

| | PACIENTE | SANGUE | RH | DOAÇÃO | CONTATO | PESO |
|---|---|---|---|---|---|---|
| 1 | Beto | B | - | 12/10/02 | (79)8801.2017 | 70 |
| 2 | Clô | O | + | 11/09/04 | (79)9941.1388 | 72 |
| 3 | Gil | AB | - | 02/02/05 | (81)2212.6711 | 95 |
| 4 | Sara | A | - | 10/01/04 | (11)2213.0909 | 73 |
| 5 | Zé | A | + | 12/12/03 | (79)223.1542 | 80 |

# Arquivos Sequenciais Ordenados (fisicamente)

- Operações

# Arquivos Sequenciais Ordenados (fisicamente)

- Alterações nos registros
  - Inserir
  - Remover
  - Alterar

- Essas operações geralmente são feitas agrupando-se as transações de atualização em lotes. Essa atualização pode ser realizada com certo atraso, de acordo com a aplicação, sendo as atualizações gravadas em arquivos de movimento ou de transações.

- O arquivo sequencial existente é denominado arquivo mestre.
  - Os arquivos mestre e de transações devem estar classificados pelo mesmo critério.
- O processo usual dessa atualização é chamado de *balanced line*

# Arquivos Sequenciais Ordenados (fisicamente)

- Inserção
  - Soluções para inserção
    - Cópia em arquivo auxiliar
    - Lote (*Balance-Line*)
    - Movimentação de registros

# Arquivos Sequenciais Ordenados (fisicamente)

- Remoção
  - Soluções para remoção
    - Lote (*Balance-Line*)
    - Uso de flag (campo adicional), para marcar o estado do registro como "excluído"
      - Pesquisa e leitura ignoram tais registros

# Arquivos Sequenciais Ordenados (fisicamente)

- Consulta
  - Em uma mídia de acesso direto, pode-se usar pesquisa binária ou por interpolação (mais eficiente).

# Arquivos Sequenciais Ordenados (fisicamente)

- Alteração
  - Pode causar aumento do tamanho do registro
  - Pode modificar valor do campo usado como chave de ordenação
    - *Balance-line*

# Arquivos Sequenciais Ordenados (fisicamente)

- Vantagem: Acesso sequencial de um conjunto de dados é o mais rápido.
- Útil quando é preciso processar quase todos os elementos.
- Desvantagens: Inclusão e Exclusão é extremamente custosa.

# Arquivos Sequenciais Ordenados por Links

- Para permitir uma recuperação rápida de registros na ordem da chave de busca, os registros são encadeados por ponteiros.

- O ponteiro em cada registro aponta para o próximo registro na ordem da chave de busca.

# Arquivos Sequenciais Ordenados por Links

- Inserção

| | | | | |
|---|---|---|---|---|
| 1 | 3 | Ademar | 32 | 5000 |
| 2 | 5 | Roberto | 25 | 7500 |
| 3 | 10 | Gerson | 43 | 6000 |
| 4 | 12 | Yeda | 23 | 9000 |
| 5 | 30 | Bernardo | 21 | 4500 |
| 6 | 50 | Ângela | 29 | 5000 |
| | | | | |
| | | | | |

Overflow

# Arquivos Sequenciais Ordenados por Links

- Inserção

| | | | | |
|---|---|---|---|---|
| | 3 | Ademar | 32 | 5000 |
| | 5 | Roberto | 25 | 7500 |
| | 10 | Gerson | 43 | 6000 |
| | 12 | Yeda | 23 | 9000 |
| | 30 | Bernardo | 21 | 4500 |
| | 50 | Ângela | 29 | 5000 |
| | 15 | Vanessa | 28 | 6000 |
| | | | | |

Overflow

Inserir o registro de chave de ordenação 15.

# Arquivos Sequenciais Ordenados por Links

- Remoção
  - Para efetuar a exclusão em arquivos sequenciais ordenados por links é recomendada a remoção lógica dos registros, por meio do ajuste de ponteiros, tomando o devido cuidado para posterior reutilização dos espaços livres.
    - Pode-se também fazer uso de *flags*
  - E a remoção física?

# Arquivos Sequenciais Ordenados

## Contiguidade Física

- Mais natural
- Acesso serial
- Acesso direto se a chave for o número lógico do registro

## Lista Encadeada

- Acesso sequencial
- Inserção/remoção mais rápida do que no físico contíguo

# Arquivos Heap

# Arquivos Heap

- Arquivos Heap são arquivos sequenciais que não estão ordenados fisicamente.
- Toda inserção é feita no final do arquivo
- A busca fica prejudicada porque é necessário sempre varrer todo o arquivo

# Tipos de Arquivo

- Arquivo HEAP

5 – Alface
1 – Rúcula
8 – Alcachofra
7 – Brócolis
2 – Couve-Flor
4 – Agrião
3 – Acelga

- Arquivo SEQUENCIAL

1 – Rúcula
2 – Couve-Flor
3 – Acelga
4 – Agrião
5 – Alface
7 – Brócolis
8 – Alcachofra

5 – Alface
1 – Rúcula
8 – Alcachofra
7 – Brócolis
2 – Couve-Flor
4 – Agrião
3 – Acelga

# Arquivos Sequenciais

**Inserção** (sem checar redundância de dados)

| Arquivo Sequencial *(tamanho n)* | Processo | Custo | Uso de Espaço |
|---|---|---|---|
| Desordenado | Em final de arquivo | *constante* | $n$ |
| Ordenado Fisicamente | Com cópia de arquivo | *linear* | $2.n$ |
| | Com movimentação de dados | *linear (no pior caso)* | $n$ |
| | Usando lote de tamanho m | *linear* | $2.n + m$ |

# Arquivos Sequenciais

**Busca Específica**

| Arquivo Sequencial *(tamanho n)* | Custo | Uso de Espaço |
|---|---|---|
| **Desordenado** | linear | n |
| **Ordenado Fisicamente** | logarítmico | n |

**Busca Total**

| Arquivo Sequencial *(tamanho n)* | Custo | Uso de Espaço |
|---|---|---|
| **Desordenado** | linear | n |
| **Ordenado Fisicamente** | linear | n |

# Arquivo Direto

# Arquivo de Acesso Direto

- Arquivos de acesso direto são aqueles nos quais para ter acesso a um registro não é necessário fazer referência ou ter acesso a demais registros do arquivo.

- Nesse tipo de arquivo a recuperação dos registros é feita diretamente pelo seu respectivo endereço, que pode ser obtido por transformações aritméticas.

# Arquivo de Acesso Direto

- Endereçamento

POSIÇÃO INICIAL = (I - 1) X COMPRIMENTO DO REGISTRO

- Hashing

endereço do registro ← hash(chave)
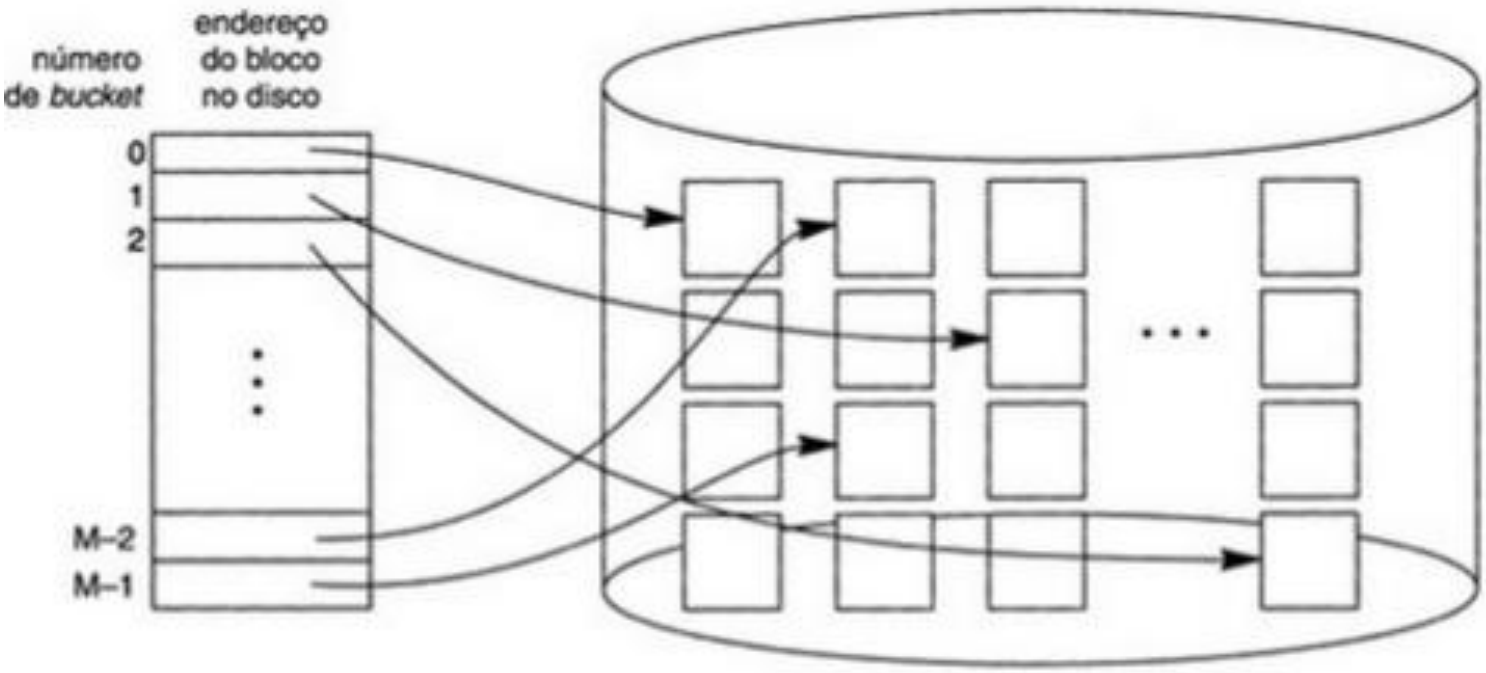
# Arquivo de Acesso Direto